



Project 11 – Αναφορά



Ανεξάρτητες ερευνητικές εργασίες

Τεχνητή νοημοσύνη στην ογκολογία

Υπολογιστική Ογκολογία

ΕΡΕΥΝΗΤΙΚΗ ΕΡΓΑΣΙΑ

Αξιολόγηση της αποδοτικότητας του αλγορίθμου k -Κοντινότερων Γειτόνων (k -NN) στην ταξινόμηση δειγμάτων αδενοκαρκινώματος των παγκρεατικών πόρων υπό συνθήκες μεταβαλλόμενου θορύβου δεδομένων

Έρευνα: Βαβουλίδης Μιλτιάδης – Ζαχαρίας

Συγγραφή: Βαβουλίδης Μιλτιάδης – Ζαχαρίας



Ανεξάρτητες ερευνητικές εργασίες
Βιοϊατρική Μηχανική
Τεχνητή νοημοσύνη στην ογκολογία
Υπολογιστική ογκολογία

-2026-

Αφιερώνεται σε όλους τους ανθρώπους που παλεύουν με τον καρκίνο, με την ελπίδα ότι θα συμβάλλει στην παγκόσμια έρευνα για την καταπολέμηση του, ώστε στο τέλος να νικήσουμε εμείς και όχι αυτός.

Βαβουλίδης Μιλτιάδης - Ζαχαρίας



ΠΕΡΙΛΗΨΗ

Τα διαρκώς αυξανόμενα περιστατικά καρκίνου ανά την υφήλιο, καθιστούν την ανάγκη για έρευνα υψηλότερη από ποτέ. Η έρευνα αφορά τόσο σε επίπεδο έγκαιρης διάγνωσης όσο και σε επίπεδο αποτελεσματικής θεραπείας. Η παρούσα έρευνα, εστιάζει στην έγκαιρή διάγνωση μιας από τις πιο θανατηφόρες και δύσκολα ανιχνεύσιμες μορφές καρκίνου στην σύγχρονη εποχή, το αδενοκαρκίνωμα των παγκρεατικών πόρων.

Μια αναδυόμενη και πολλά υποσχόμενη επιστημονική μέθοδος ανίχνευσης καρκίνου σε έναν οργανισμό, αφορά στην χρήση αλγορίθμων τεχνητής νοημοσύνης η οποία αποσκοπεί στον εντοπισμό σημαντικών -για την ανάπτυξη καρκίνου- βιοδεικτών. Λόγω του γεγονότος ότι αυτές οι τεχνικές είναι αρκετά σύγχρονες, παρατηρείται έλλειψη κατάλληλων βάσεων δεδομένων, ή στην περίπτωση που αυτές υπάρχουν χαρακτηρίζονται από διάφορα τεχνικά προβλήματα οποία ο ερευνητής καλείται να ξεπεράσει (π.χ. μέσω προεπεξεργασίας δεδομένων).

Στην παρούσα ερευνητική εργασία, γίνεται μια προσπάθεια μελέτης της συσχέτισης ορισμένων βιοδεικτών και της ικανότητας ταξινόμησης δειγμάτων από τον αλγόριθμο μηχανικής μάθησης κ-κοντινότερων γειτόνων. Συγκεκριμένα πραγματοποιείται μια αξιολόγηση του αλγορίθμου αυτού αναφορικά με την ικανότητα του να ταξινομεί δείγματα σε ασθενείς και υγιείς, με βάση τους βιοδείκτες αυτούς καθώς και το πόσο εύρωστος είναι σε περιβάλλον αυξανόμενης παρουσίας θορύβου.

Συνοπτικά η ανάλυση χωρίζεται σε διάφορα στάδια. Στο αρχικό στάδιο ελέγχεται η ικανότητα του αλγορίθμου στην ταξινόμηση δειγμάτων με βάση βιοδείκτες οι οποίοι είναι γνωστό στην επιστημονική κοινότητα ότι επηρεάζονται από την παρουσία αδενοκαρκινώματος, ενώ στα επόμενα στάδια εισάγονται -κλιμακωτά- επιπλέον δεδομένα/βιοδείκτες για τους οποίους δεν έχει βρεθεί κάποια συσχέτιση με το αδενοκαρκίνωμα. Με αυτόν τον τρόπο, επιδιώκεται η μοντελοποίηση του θορύβου και ο έλεγχος της ικανότητας ταξινόμησης δειγμάτων από τον αλγόριθμο παρουσία θορύβου.

Τα αποτελέσματα της παρούσης έρευνας επιβεβαιώνουν την γενική θεωρητική γνώση περί μη ευρωστίας του αλγορίθμου ενώ παρουσιάζονται και πίνακες σχετικοί με τον ρυθμό πτώσης της κάθε μετρικής εξατομικευμένα για βέλτιστη και ολιστική αξιολόγηση της συμπεριφοράς του αλγορίθμου.

Η αξία τούτης της έρευνας έγκειται στο γεγονός ότι συμβάλει στην αξιολόγηση της ικανότητας ταξινόμησης δειγμάτων του αλγορίθμου κ-κοντινότερων γειτόνων σε υγιείς και ασθενείς (αδενοκαρκίνωμα) παρουσία θορύβου και στον ενδεχόμενο εντοπισμό βιοδεικτών που σχετίζονται με το αδενοκαρκίνωμα που έως τώρα η επιστημονική κοινότητα αγνοούσε.



Ανεξάρτητες ερευνητικές εργασίες
Βιοϊατρική Μηχανική
Τεχνητή νοημοσύνη στην ογκολογία
Υπολογιστική ογκολογία

-2026-

Συνολικά, επιδιώκει να συμβάλει στην παγκόσμια έρευνα για την αποτελεσματικότερη και έγκαιρη διάγνωση σε περιπτώσεις αδενοκαρκινώματος.



ABSTRACT

Title: Evaluation of Performance and Robustness of the k-Nearest Neighbors (kNN) Algorithm in the Classification of Pancreatic Ductal Adenocarcinoma Samples Under Conditions of Varying Data Noise.

Background: Pancreatic Ductal Adenocarcinoma (PDAC) remains one of the most lethal and elusive forms of cancer, underscoring an urgent need for reliable early diagnostic methods. Artificial intelligence and computational oncology offer promising tools for identifying crucial biomarkers. However, a primary challenge in modern biomedical applications is the susceptibility of machine learning algorithms to dataset noise and irrelevant features.

Objective: This study evaluates the diagnostic classification efficacy and systemic robustness of the k-Nearest Neighbors (k-NN) algorithm under varying levels of data noise. The primary goal is to determine the impact of non-correlated biological features on the model's ability to accurately differentiate between healthy individuals and PDAC patients.

Methodology: Utilizing simulated clinical datasets modeled strictly after realistic biochemical ranges of 200 samples (100 healthy and 100 PDAC), a multi-stage experimental analysis was conducted. Version 1 established a baseline using 10 recognized PDAC-related biomarkers (zero noise). Versions 2, 3, and 4 iteratively introduced 10, 20, and 40 non-correlated biomarkers, respectively, to simulate scalable data noise. Evaluation was performed using Monte Carlo Cross Validation over 50 iterations per model configuration, optimizing hyperparameter k values ($k = 3, 5, 9, 11$) across standard performance metrics: Accuracy, Precision, Recall, F1-Score, and AUC-ROC.

Results: The experimental findings confirm the theoretical lack of robustness inherent to the k-NN algorithm when exposed to data noise. While the model demonstrated absolute robustness in Precision (maintaining 100% across all versions with zero false positives), it suffered a severe, catastrophic degradation in Recall. The mean Recall dropped from 98.2% in Version 1 to a completely prohibitive 44.7% in Version 4. Additionally, the introduction of the initial layer of noise (Version 1 to Version 2) triggered a dramatic 1682.25% spike in execution time. Higher k values marginally mitigated AUC-ROC decay but actively worsened Recall performance in high-noise environments.

Conclusion: Due to the life-and-death stakes of biomedical oncological applications, the high rate of false negatives (low Recall) induced by noise renders the standalone kNN algorithm unacceptable for real-world diagnostic datasets. For clinical viability, the integration of robust



automated feature selection techniques is mandatory prior to classification. Future research should validate these computational behaviors using expanded real-world clinical patient data.

Keywords: Computational Oncology, Pancreatic Ductal Adenocarcinoma (PDAC), k-Nearest Neighbors (k-NN), Algorithmic Robustness, Data Noise, Biomarkers, Recall Degradation.



Πίνακας περιεχομένων

ΕΙΣΑΓΩΓΗ	8
ΤΕΧΝΙΚΗ ΑΝΑΛΥΣΗ	11
Ο αλγόριθμος των κ-κοντινότερων γειτόνων (kNN)	11
Μετρικές αξιολόγησης	13
Τα δεδομένα που χρησιμοποιήθηκαν	16
1 ^ο στάδιο	17
2 ^ο στάδιο	18
3 ^ο στάδιο	19
4 ^ο στάδιο	21
ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ	23
Χρόνος εκτέλεσης των μοντέλων	25
Μετρικές αξιολόγησης της απόδοσης	27
Accuracy	28
Precision	35
Recall	42
F1 – Score	49
AUC – ROC	56
Μετρικές του confusion matrix	63
True Positives	64
True Negatives	65
False Positives	66
False Negatives	67
ΣΥΜΠΕΡΑΣΜΑΤΑ	68
ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΛΛΟΝΤΙΚΗ ΕΡΕΥΝΑ	69



ΕΙΣΑΓΩΓΗ

Ο καρκίνος είναι μια ομάδα ασθενειών που χαρακτηρίζονται από ανώμαλη και μη ελεγχόμενη ανάπτυξη κυττάρων σε μια περιοχή ή όργανο. Αρκετές φορές, αυτή η ανάπτυξη δεν περιορίζεται μόνο σε μια περιοχή ή σε ένα όργανο τοπικά, αλλά εξαπλώνεται και σε άλλες. Η ιδιότητα αυτή ονομάζεται μετάσταση και αξιολογείται ως μια από τις κύριες αιτίες για τις οποίες ο καρκίνος είναι θανατηφόρος.

Στην σημερινή εποχή, είναι γνωστοί περισσότεροι από 100 τύποι καρκίνου που επηρεάζουν τον άνθρωπο, με διαφορετικά χαρακτηριστικά και διαφορετικά ποσοστά θνησιμότητας αποτελώντας μια από τις συχνότερες αιτίες θανάτου των ανθρώπων σε παγκόσμιο επίπεδο. Σύμφωνα με τα τελευταία δεδομένα, που προέρχονται από τον Παγκόσμιο Οργανισμό Υγείας (Π.Ο.Υ.), ετησίως, ο καρκίνος είναι η αιτία από την οποία νοσούν και πεθαίνουν περίπου 11.000.000 άνθρωποι, ποσοστό που αντιστοιχεί περίπου στο 20% επί των συνολικών θανάτων.

Τα παραπάνω νούμερα, καθιστούν τον καρκίνο ως την 2η συχνότερη αιτία θανάτου παγκοσμίως αφήνοντας τον πίσω μόνο από τις καρδιαγγειακές ασθένειες. Αφενός, με μια βαθύτερη μελέτη, διαπιστώνεται ότι η πληθώρα των θανάτων από καρδιαγγειακά νοσήματα αφορά σε περιστατικά άνω των 70 ετών ενώ του καρκίνου όχι. Αυτό οδηγεί στο τρομακτικό συμπέρασμα ότι ο καρκίνος, σε ηλικίες κάτω των 70 ετών είναι η πρώτη αιτία θανάτου παγκοσμίως. Αφετέρου, παρατηρείται αυξητική τάση των περιστατικών καρκίνου τα τελευταία χρόνια. Τα δύο αυτά συμπεράσματα αναδύουν στην επιφάνεια την ανάγκη για άμεση και περαιτέρω κινητοποίηση της επιστημονικής κοινότητας προς την κατεύθυνση της καταπολέμησης του καρκίνου.

Στον παρακάτω πίνακα παρουσιάζονται τα ποσοστά 5ετούς επιβίωσης ανά στάδιο διάγνωσης για 10 διαφορετικούς τύπος καρκίνου:

Τύπος καρκίνου	Στάδιο 1	Στάδιο 2	Στάδιο 3	Στάδιο 4
Καρκίνος παγκρέατος	39-44%	20-25%	10-15%	3%
Καρκίνος μαστού	>99%	93-95%	86%	30%
Καρκίνος πνεύμονα	65%	53%	37%	9%
Καρκίνος παχέος εντέρου	91%	82%	72%	14%
Καρκίνος δέρματος	99%	90%	71%	35%



Καρκίνος προστάτη	>99%	>99%	>99%	34%
Καρκίνος ουροδ. κύστης	96%	75%	39%	8%
Καρκίνος νεφρού	93%	85%	72%	15%
Καρκίνος Ωοθηκών	93%	75%	41%	31%
Καρκίνος στομάχου	75%	55%	35%	7%

Από την μελέτη του παραπάνω πίνακα, προκύπτει ένα ανησυχητικό συμπέρασμα αναφορικά με τα ποσοστά 5ετούς επιβίωσης στις διαφορετικές περιπτώσεις καρκίνου. Συγκεκριμένα, σε όλες τις περιπτώσεις καρκίνου, παρατηρείται ότι όσο νωρίτερα πραγματοποιείται η διάγνωση, τόσο καλύτερη πρόγνωση δίνεται στον ασθενή, δηλαδή τόσο υψηλότερες είναι οι πιθανότητες επιβίωσης του ασθενούς. Έτσι, κρίνεται απαραίτητη η ενίσχυση της επιστημονικής έρευνας γύρω από το πεδίο της έγκαιρης διάγνωσης.

Ένα επιπλέον συμπέρασμα που προκύπτει από τον παραπάνω πίνακα, αφορά στο γεγονός ότι το αδενοκαρκίνωμα των παγκρεατικών πόρων (Pancreatic Ductal Adenocarcinoma - PDAC), αποτελεί την πιο θανατηφόρα (ανεξαρτήτως σταδίου διάγνωσης) περίπτωση καρκίνου ανάμεσα στις προαναφερθείσες καθώς και μια από τις πιο θανατηφόρες ανάμεσα σε όλες τις περιπτώσεις καρκίνου ανά τον κόσμο. Το παραπάνω συμπέρασμα, αποτελεί την κύρια αιτία για την οποία η παρούσα έρευνα αφορά στην μελέτη του PDAC.

Τα παραπάνω στατιστικά συμπεράσματα έχουν προκύψει από διαρκή μελέτη περιστατικών καρκίνου στα οποία ακολουθείται συνήθως η παρακάτω διαδικασία (ή μέρος αυτής) για την διάγνωση τους:

- Κλινική εικόνα:
 - ο Συμπτώματα: Αδυναμία, αιμόπτυση, ζαλάδες, πόνος
 - ο Παράγοντες κινδύνου: Κάπνισμα, οικογενειακό ιστορικό
 - ο Φυσική εξέταση: Μακροσκοπική οπτική εξέταση, τοπική αφή
- Εργαστηριακός έλεγχος:
 - ο Ανάλυση γενικών βιοδεικτών: Λευκά αιμοσφαίρια
 - ο Οργανική λειτουργία/επάρκεια: Νεφρικός έλεγχος, Υπατικός έλεγχος
 - ο Ανάλυση συγκεκριμένων βιοδεικτών: PSA για καρκίνο του προστάτη, CA-125 για καρκίνο των Ωοθηκών, AFP για καρκίνο του ήπατος



- Τεχνικές απεικόνισης:
 - Ακτινογραφία
 - Υπέρηχος
 - Αξονική τομογραφία
 - Μαγνητική τομογραφία
 - Τομογραφία εκπομπής ποζιτρονίων
- Βιοψία/Ιστολογική εξέταση:
 - Βιοψία αφαίρεσης ιστού με χρήση ειδικής βελόνας
 - Βιοψία αφαίρεσης ιστού μέσω τομής με χειρουργικό νυστέρι

Η χρήση των παραπάνω τεχνικών διάγνωσης, αφορά στο πρωτόκολλο που εφαρμόζεται παγκοσμίως στις μέρες μας. Η διαρκής έρευνα, η οποία έχει ως σκοπό την αποτελεσματικότερη διάγνωση του καρκίνου, συχνά έχει ως αποτέλεσμα την αναθεώρηση αυτού του πρωτοκόλλου είτε μέσω ανακάλυψης νέων τεχνικών διάγνωσης είτε μέσω ανανέωσης των υφισταμένων.

Ένα από τα πιο σύγχρονα «όπλα» της ανθρωπότητας ακούει στο όνομα «Βιοϊατρική Μηχανική» (Biomedical Engineering). Η βιοϊατρική μηχανική αποτελεί έναν διεπιστημονικό κλάδο που αφορά στην εφαρμογή αρχών μηχανικής (Στατιστική Ανάλυση, Τεχνητή Νοημοσύνη, Μαθηματική Ανάλυση, Γραμμική Άλγεβρα) σε εφαρμογές υγείας και βιοϊατρικά δεδομένα.

Σε αυτό το πλαίσιο, μια αναδυόμενη και πολλά υποσχόμενη μέθοδος διάγνωσης αφορά στην χρήση εργαλείων τεχνητής νοημοσύνης. Συγκεκριμένα, χρησιμοποιούνται αλγόριθμοι/μοντέλα ταξινόμησης (ταξινομητές), οι οποίοι εκπαιδεύονται κατάλληλα με σκοπό να αποκτήσουν την ικανότητα να ταξινομούν (ξεχωρίζουν) δείγματα σε ασθενείς και υγιείς.

Η παρούσα έρευνα επικεντρώνεται στην μελέτη της ικανότητας ταξινόμησης δειγμάτων σε υγιείς και ασθενείς (PDAC) του αλγορίθμου κ-κοντινότερων γειτόνων (k-Nearest Neighbor kNN) παρουσία θορύβου, δηλαδή χαρακτηριστικών (βιοδεικτών) τα οποία έως τώρα είναι μη σχετιζόμενα με την ανάπτυξη PDAC. Αρχικά, η ανάλυση περιορίζεται χωρίς παρουσία θορύβου ενώ καθώς προχωράει η μελέτη, η παρουσία αυτού αυξάνεται. Σκοπός της μελέτης είναι να ελεγχθεί η ικανότητα ταξινόμησης του αλγορίθμου σε συνθήκες μεταβαλλόμενου θορύβου, δηλαδή ο έλεγχος ευρωστίας του αλγορίθμου.



ΤΕΧΝΙΚΗ ΑΝΑΛΥΣΗ

Ο αλγόριθμος των κ-κοντινότερων γειτόνων (kNN)

Η παρούσα έρευνα αφορά στην μελέτη της ικανότητας ταξινόμησης δειγμάτων σε υγιείς και ασθενείς (που πάσχουν από PDAC) του αλγορίθμου μηχανικής μάθησης kNN παρουσία μεταβαλλόμενων επιπέδων θορύβου.

Ένα μοντέλο κ-κοντινότερου γείτονα, (kNN) είναι ένας τύπος ταξινομητή που χρησιμοποιείται κατά κόρον σε εφαρμογές ταξινόμησης δεδομένων σε κλάσεις.

Τα κυριότερα τεχνικά χαρακτηριστικά ενός τέτοιου μοντέλου, είναι:

- **Αριθμός γειτόνων (Number of neighbors):** Ο αριθμός των κοντινότερων δειγμάτων με βάση τον οποίον θα πραγματοποιηθεί η ταξινόμηση του νέου δείγματος.
- **Μετρική απόστασης (Distance Metric):** Η μετρική με βάση την οποία υπολογίζονται οι αποστάσεις μεταξύ των δειγμάτων. Συνήθως πρόκειται για την Ευκλείδεια απόσταση.

Τονίζεται ότι οι τιμές των παραπάνω τεχνικών χαρακτηριστικών διαφοροποιούνται από εφαρμογή σε εφαρμογή, με άξονα την βελτιστοποίηση των αποτελεσμάτων της εκάστοτε εφαρμογής.

Παρακάτω, παρουσιάζεται η αρχή λειτουργίας ενός τέτοιου μοντέλου:

1. **Αποθήκευση δεδομένων εκπαίδευσης (Save Training Data):** Τα δεδομένα εκπαίδευσης (training data - καταχρηστική χρήση του όρου) είναι τα δεδομένα των οποίων η κλάση είναι γνωστή. Με βάση αυτά τα δεδομένα, ταξινομούνται τα υπόλοιπα, νέα δείγματα.
2. **Επιλογή αριθμού γειτόνων και μετρικής απόστασης (Select «k» value and distance metric):** Αρχικά επιλέγονται τιμές για τον αριθμό των γειτόνων και για την μετρική απόστασης που θα χρησιμοποιηθεί από το μοντέλο.
3. **Εντοπισμός κ-κοντινότερων γειτόνων (Find «k» nearest neighbors):** Για κάθε δείγμα προς ταξινόμηση, γίνεται ο υπολογισμός των αποστάσεων μεταξύ του εν λόγω δείγματος και όλων των δεδομένων εκπαίδευσης. Έπειτα, εντοπίζονται οι κ-κοντινότεροι γείτονες του, δηλαδή τα «κ» -σε αριθμό- δείγματα από τα δεδομένα



εκπαίδευσης των οποίων η απόσταση μεταξύ αυτών και του δείγματος προς ταξινόμηση είναι η μικρότερη.


4. **Ταξινόμηση (Classification):** Μετά τον εντοπισμό των κ-κοντινότερων γειτόνων, το δείγμα ταξινομείται με βάση την κλάση που ανήκουν οι περισσότεροι από αυτούς τους γείτονες. Σύμφωνα με την μέθοδο που χρησιμοποιείται περισσότερο από όλες τις άλλες, η συνεισφορά του κάθε γείτονα ως προς την ταξινόμηση του δείγματος είναι ίδια, δηλαδή η απόφαση λαμβάνεται πλειοψηφικά.

Τα σημαντικότερα πλεονεκτήματα των μοντέλων αυτών είναι:

- Πολύ απλά και εύκολα υλοποιήσιμα.
- Εύκολα ερμηνεύσιμα.
- Λίγες παράμετροι.
- Τα μοντέλα αυτά χαρακτηρίζονται ως «ευέλικτα», καθώς μπορούν να χρησιμοποιηθούν σε μια διαφορετικές εφαρμογές με μηδενικές -πολλές φορές- προσαρμογές.

Τα σημαντικότερα μειονεκτήματα των μοντέλων αυτών είναι:

- Λόγω του υπολογισμού πολλών τιμών της μετρικής απόστασης (π.χ. Ευκλείδειας απόστασης) μεταξύ δειγμάτων, ενδέχεται να είναι υπολογιστικά απαιτητικός.
- Λόγω της αποθήκευσης των δεδομένων εκπαίδευσης, σε περιπτώσεις όπου το dataset είναι πολύ μεγάλο, απαιτείται πολλή μνήμη.
- Ευαισθησία σε μη σχετικά χαρακτηριστικά ή χαρακτηριστικά που περιέχουν θόρυβο.
- Ευαισθησία ως προς τις παραμέτρους.





Μετρικές αξιολόγησης

Οι μετρικές που χρησιμοποιήθηκαν για την αξιολόγηση της απόδοσης του αλγορίθμου kNN είναι οι:

- **Accuracy**

Αυστηρώς μαθηματικά ορίζεται ως ο λόγος του πλήθους των ορθώς ταξινομημένων δειγμάτων προς το σύνολο των δειγμάτων. Δηλαδή:

$$\text{Accuracy} = \frac{TP+TN}{TP+TN+FP+FN}$$

Η accuracy, είναι από τις σημαντικότερες και ευρέως χρησιμοποιούμενες μετρικές αξιολόγησης μοντέλων, καθώς παρέχει μια απλή, εύκολα κατανοητή, μακροσκοπική και ουσιώδη αντίληψη αναφορικά με την ικανότητα ταξινόμησης δειγμάτων από το μοντέλο.

- **Confusion Matrix**

Ο «confusion matrix» είναι μια μετρική αξιολόγησης μοντέλων μηχανικής μάθησης που χρησιμοποιείται ευρέως σε εφαρμογές ταξινόμησης.

Ο αυστηρός του ορισμός φαίνεται παρακάτω:

-	Actually Positive (1)	Actually Negative (0)
Predicted Positive (1)	True Positives (TPs)	False Positives (FPs)
Predicted Negative (0)	False Negatives (FNs)	True Negatives (TNs)

όπου:

- **True Positives (TPs)**: Ο αριθμός των θετικών δειγμάτων τα οποία το μοντέλο ορθώς ταξινόμησε ως θετικά.
- **True Negatives (TNs)**: Ο αριθμός των αρνητικών δειγμάτων τα οποία το μοντέλο ορθώς ταξινόμησε ως αρνητικά.
- **False Positives (FPs)**: Ο αριθμός των αρνητικών δειγμάτων τα οποία το μοντέλο λανθασμένα ταξινόμησε ως θετικά.



- **False Negatives (FNs)**: Ο αριθμός των θετικών δειγμάτων τα οποία το μοντέλο λανθασμένα ταξινομήσε ως αρνητικά.

Η εν λόγω μετρική παρουσιάζει ιδιαίτερο ενδιαφέρον καθώς, σε αντίθεση με την accuracy η οποία δίνει μια μακροσκοπική οπτική, αυτή παρουσιάζει μια πιο αναλυτική, λεπτομερή, «εσωτερική», απεικόνιση αναφορικά με την ικανότητα ταξινόμησης του μοντέλου.

Η πολύ σημαντική αξία της μετρικής αυτής φαίνεται σε κρίσιμες εφαρμογές, όπως οι βιοϊατρικές. Για παράδειγμα, σε περίπτωση που η ακρίβεια ενός μοντέλου ταξινόμησης δειγμάτων σε κλάσεις «καρκινοπαθής» και «μη καρκινοπαθής» είναι 97%, πιθανότατα αυτό το μοντέλο θα χαρακτηριστεί ως «ικανοποιητικό», λόγω της μακροσκοπικής οπτικής που παρέχει η έννοια «ακρίβεια». Ωστόσο, εάν πραγματοποιηθεί μελέτη του πίνακα σύγχυσης, ενδεχομένως να διαπιστωθεί ότι αυτές οι 3 στις 100 περιπτώσεις δειγμάτων, αφορούν σε περιπτώσεις που ενώ πραγματικά ανήκουν στην κλάση «καρκινοπαθής», ταξινομήθηκαν από το μοντέλο ως «μη καρκινοπαθείς». Φυσικά, αυτό το σφάλμα στην ταξινόμηση θα οδηγήσει στον θάνατο αυτών των ανθρώπων. Καθίσταται σαφές ότι, αυτό -το ίδιο- μοντέλο, έπειτα από την ανάλυση μέσω πίνακα σύγχυσης, σίγουρα -πλέον- δεν μπορεί να χαρακτηριστεί ως «ικανοποιητικό».

- **Precision**

Αυστηρώς μαθηματικά, ορίζεται ως ο λόγος του πλήθους των TP προς το σύνολο των positive προβλέψεων. Δηλαδή:

$$\text{Precision} = \frac{TP}{TP+FP}$$

Η «precision» ταξινόμησης, είναι από τις σημαντικότερες και ευρέως χρησιμοποιούμενες μετρικές αξιολόγησης μοντέλων. Πρακτικά απαντάει στην ερώτηση «Από όλες τις positive προβλέψεις, πόσες είναι στ' αλήθεια positive;». Αποτελεί μια κρίσιμη μετρική σε περιπτώσεις όπου τα FP, κοστίζουν.

- **Recall**

Αυστηρώς μαθηματικά, ορίζεται ως ο λόγος του πλήθους των TP προς το σύνολο των πραγματικά positive δειγμάτων. Δηλαδή:

$$\text{Recall} = \frac{TP}{TP+FN}$$

Η «recall» ταξινόμησης, είναι από τις σημαντικότερες και ευρέως χρησιμοποιούμενες μετρικές αξιολόγησης μοντέλων. Πρακτικά απαντάει στην ερώτηση «Από όλα τα πραγματικά positive δείγματα, πόσα προβλέφθηκαν ως positive;». Αποτελεί μια κρίσιμη μετρική σε περιπτώσεις όπου τα FN, κοστίζουν.



- **F1-Score**

Αυστηρώς μαθηματικά, ορίζεται ως η αρμονική μέση τιμή (αρμονικός μέσος όρος) της precision και της recall. Δηλαδή:

$$F1-Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

Η F1-Score, «ισορροπεί» την precision και την recall. Είναι πολύ χρήσιμη όταν παρατηρείται ανισορροπία στην κατανομή των δειγμάτων σε κλάσεις ή όταν τόσο τα FP όσο και τα FN είναι κρίσιμα.

- **AUC-ROC**

Αυστηρώς μαθηματικά, ορίζεται ως η πιθανότητα, το μοντέλο να ταξινομήσει ένα τυχαία επιλεγμένο positive δείγμα υψηλότερα από ένα τυχαία επιλεγμένο negative δείγμα. Δηλαδή:

$$AUC-ROC = \int_0^1 TPR(FPR) dfPR$$

Η AUC-ROC λαμβάνει τιμές στο διάστημα [0, 1]. Υψηλότερες τιμές υποδεικνύουν καλύτερη απόδοση του μοντέλου



Τα δεδομένα που χρησιμοποιήθηκαν

Λόγω της έλλειψης πραγματικών δεδομένων, τα δεδομένα που χρησιμοποιήθηκαν αφορούν εικονικά δεδομένα (dummy data) τα οποία αντιστοιχούν σε γνωστούς, υπάρχοντες βιοδείκτες. Παρά το γεγονός ότι τα δεδομένα είναι εικονικά, οι τιμές οι οποίες λαμβάνουν ορίζονται από τα πραγματικά όρια τιμών των αντίστοιχων πραγματικών κλινικών δεδομένων, με σκοπό την βέλτιστη προσομοίωση της πραγματικότητας.

Η ανάλυση χωρίζεται σε 4 στάδια. Σε κάθε στάδιο ανάλυσης, αυξάνεται ο θόρυβος ο οποίος εισάγεται στα δεδομένα για να ελεγχθεί η ικανότητα ταξινόμησης του kNN παρουσία θορύβου και ο τρόπος με τον οποίο επηρεάζεται από αυτόν. Τονίζεται ότι, τεχνικά, η έννοια του θορύβου στην παρούσα ανάλυση αφορά στην εισαγωγή δεδομένων των οποίων η τιμή παρουσιάζει ελάχιστη διακύμανση ανεξαρτήτως κατηγορίας δείγματος (ασθενούς ή μη).

Σε κάθε στάδιο ανάλυσης χρησιμοποιούνται 200 δείγματα (samples). Τα 100 αφορούν σε περιπτώσεις υγείων ενώ τα υπόλοιπα 100 αφορούν σε περιπτώσεις ανθρώπων που πάσχουν από PDAC. Όπως αναφέρθηκε και προηγουμένως, τα χαρακτηριστικά (features) του σετ δεδομένων (dataset) αφορούν σε γνωστούς, υπάρχοντες βιοδείκτες του ανθρώπινου οργανισμού.

- **1^ο στάδιο:** Χρήση 10 βιοδεικτών οι οποίοι είναι γνωστό στην επιστημονική κοινότητα ότι σχετίζονται με την ανάπτυξη PDAC. Η παρουσία θορύβου σε αυτή την περίπτωση είναι μηδενική.
- **2^ο στάδιο:** Έναρξη εισαγωγής θορύβου. Το dataset εμπλουτίζεται με επιπλέον 10 βιοδείκτες, οι οποίοι -σύμφωνα με τις έως τώρα έρευνες- δεν σχετίζονται με την ανάπτυξη PDAC.
- **3^ο στάδιο:** Αύξηση εισαγωγής θορύβου. Το dataset εμπλουτίζεται με επιπλέον 20 βιοδείκτες (συνολικά 30), οι οποίοι -σύμφωνα με τις έως τώρα έρευνες- δεν σχετίζονται με την ανάπτυξη PDAC.
- **4^ο στάδιο:** Περαιτέρω αύξηση εισαγωγής θορύβου. Το dataset εμπλουτίζεται με επιπλέον 20 βιοδείκτες (συνολικά 50), οι οποίοι -σύμφωνα με τις έως τώρα έρευνες- δεν σχετίζονται με την ανάπτυξη PDAC.

Σε μια τεχνική λεπτομέρεια, τονίζεται ότι η έννοια του θορύβου αφορά στα χαρακτηριστικά του dataset τα οποία -σύμφωνα με τις έως τώρα έρευνες- δεν σχετίζονται με την ανάπτυξη PDAC.



1^ο στάδιο

Το πρώτο στάδιο της ανάλυσης αφορά στην περίπτωση όπου ελέγχεται η ικανότητα ταξινόμησης δειγμάτων από τον kNN, με βάσει 10 βιοδείκτες που είναι γνωστό ότι σχετίζονται με την ανάπτυξη PDAC.

Αυστηρώς μαθηματικά, η συσχέτιση αυτή σημαίνει ότι το εύρος τιμών των βιοδεικτών αυτών στην περίπτωση ενός ασθενούς με PDAC, διαφέρει σημαντικά από το εύρος τιμών ενός υγιούς δείγματος.

Για την παρούσα ανάλυση χρησιμοποιήθηκαν οι 10 βιοδείκτες που φαίνονται στον παρακάτω πίνακα. Σημειώνεται ότι στις στήλες «Υγιής» και «Ασθενής», οι τιμές αφορούν την μέση τιμή του αντίστοιχου βιοδείκτη καθώς και την τυπική του απόκλιση.

Βιοδείκτης	Μονάδες	Υγιής	Ασθενής	Σημασία
CA 19-9	U/mL	12.5 ± 8.0	450.0 ± 210.0	Primary pancreatic tumor marker
CEA	mg/mL	1.8 ± 1.2	8.5 ± 5.5	General marker for GI tract cancer
Bilirubin (Total)	mg/dL	0.6 ± 0.3	2.4 ± 1.8	Elevated if tumor blocks bile ducts
Alkaline Phosphatase	U/L	70.0 ± 20.0	210.0 ± 95.0	Indicates liver/bile duct stress
ALT (Alanine Aminotransferase)	U/L	25.0 ± 10.0	55.0 ± 30.0	Marker for secondary liver impact
Albumin	g/dL	4.4 ± 0.4	3.2 ± 0.7	Drops due to inflammation/malnutrition
CRP (C-Reactive Protein)	mg/L	1.5 ± 1.0	15.0 ± 12.0	General systemic inflammation marker
Glucose (Fasting)	mg/dL	90.0 ± 10.0	135.0 ± 40.0	New-onset diabetes is a PDAC symptom
Hemoglobin	g/dL	14.5 ± 1.5	11.5 ± 2.0	Cancer other causes mild anemia
Platelet Count	10 ³ /μL	250 ± 50	380 ± 110	Paraneoplastic thrombocytosis (high platelets)



2^ο στάδιο

Στο 2^ο στάδιο της ανάλυσης, ξεκινάει η εισαγωγή του θορύβου. Έτσι, το 2^ο στάδιο της ανάλυσης αφορά στην περίπτωση όπου ελέγχεται η ικανότητα ταξινόμησης δειγμάτων από τον kNN, με βάσει 10 βιοδείκτες που είναι γνωστό ότι σχετίζονται με την ανάπτυξη PDAC και 10 επιπλέον βιοδείκτες οι οποίοι δεν έχουν καμία γνωστή -έως τώρα- συσχέτιση με την ανάπτυξη αυτού.

Αυστηρώς μαθηματικά, η μη συσχέτιση αυτή σημαίνει ότι το εύρος τιμών των βιοδεικτών αυτών στην περίπτωση ενός ασθενούς με PDAC, διαφέρει σημαντικά από το εύρος τιμών ενός υγιούς δείγματος.

Στην παρούσα ανάλυση, τον θόρυβο προσομοιώνουν οι 10 βιοδείκτες που φαίνονται στον παρακάτω πίνακα. Σημειώνεται ότι στις στήλες «Υγιής» και «Ασθενής», οι τιμές αφορούν την μέση τιμή του αντίστοιχου βιοδείκτη καθώς και την τυπική του απόκλιση.

Βιοδείκτης	Μονάδες	Υγιής	Ασθενής	Σημασία
<i>Vitamin B12</i>	pg/mL	450.0 ± 150.0	445.0 ± 160.0	Generally unaffected by early PDAC
<i>TSH (Thyroid)</i>	mIU/L	2.1 ± 1.1	2.2 ± 1.2	Standard thyroid function marker
<i>Calcium</i>	mg/dL	9.5 ± 0.5	9.4 ± 0.6	Bone/parathyroid marker
<i>Chloride</i>	mEq/L	102.0 ± 3.0	101.5 ± 3.5	Basic electrolyte balance
<i>Potassium</i>	mEq/L	4.1 ± 0.4	4.0 ± 0.5	Essential mineral/electrolyte
<i>Creatinine</i>	mg/dL	0.9 ± 0.2	1.0 ± 0.3	Primary marker for kidney function
<i>HDL Cholesterol</i>	mg/dL	55.0 ± 12.0	53.0 ± 14.0	“Good” cholesterol; lipid profile
<i>HBA1c</i>	%	5.3 ± 0.4	5.5 ± 0.6	3-month average blood sugar
<i>Vitamin D</i>	ng/mL	32.0 ± 10.0	30.0 ± 12.0	Bone and immune health
<i>Uric Acid</i>	mg/dL	5.0 ± 1.2	5.2 ± 1.4	Metabolic byproduct; gout marker



3^ο στάδιο

Στο 3^ο στάδιο της ανάλυσης, ενισχύεται ο θόρυβος με την εισαγωγή επιπλέον 20 βιοδεικτών. Έτσι, το 2^ο στάδιο της ανάλυσης αφορά στην περίπτωση όπου ελέγχεται η ικανότητα ταξινόμησης δειγμάτων από τον kNN, με βάσει 10 βιοδείκτες που είναι γνωστό ότι σχετίζονται με την ανάπτυξη PDAC και συνολικά 30 βιοδείκτες οι οποίοι δεν έχουν καμία γνωστή -έως τώρα- συσχέτιση με την ανάπτυξη αυτού.

Αυστηρώς μαθηματικά, η συσχέτιση αυτή σημαίνει ότι το εύρος τιμών των 30 βιοδεικτών αυτών στην περίπτωση ενός ασθενούς με PDAC, δεν διαφέρει σημαντικά από το εύρος τιμών ενός υγιούς δείγματος.

Στην παρούσα ανάλυση, τον επιπλέον θόρυβο προσομοιώνουν οι 20 βιοδείκτες που φαίνονται στον παρακάτω πίνακα. Σημειώνεται ότι στις στήλες «Υγιής» και «Ασθενής», οι τιμές αφορούν την μέση τιμή του αντίστοιχου βιοδείκτη καθώς και την τυπική του απόκλιση.

Βιοδείκτης	Μονάδες	Υγιής	Ασθενής	Σημασία
<i>Sodium</i>	mEq/L	140.0 ± 3.0	139.5 ± 3.5	Basic electrolyte
<i>Magnesium</i>	mg/dL	2.0 ± 0.3	1.9 ± 0.4	Mineral balance
<i>Phosphorus</i>	mg/dL	3.5 ± 0.5	3.6 ± 0.6	Bone/Kidney marker
<i>Total Protein</i>	g/L	7.2 ± 0.5	7.0 ± 0.8	General nutrition
<i>BUN</i>	mg/dL	15.0 ± 4.0	16.0 ± 5.0	Blood Urea Nitrogen (Kidney)
<i>LDL Cholesterol</i>	mg/dL	100.0 ± 25.0	105.0 ± 30.0	“Bad” Cholesterol
<i>Triglycerides</i>	mg/dL	130.0 ± 40.0	135.0 ± 50.0	Lipid profile
<i>Erythrocytes</i>	10 ⁶ /μL	5.0 ± 0.5	4.8 ± 0.7	Red blood cell count
<i>MCV</i>	fL	90.0 ± 5.0	89.0 ± 7.0	Average size of RBCs
<i>Mean Platelet Vol</i>	fL	10.5 ± 1.2	10.8 ± 1.5	Size of platelets
<i>Monocytes</i>	%	6.0 ± 2.0	6.2 ± 2.5	General white blood cell type
<i>Basophils</i>	%	0.5 ± 0.3	0.6 ± 0.4	Allergy/Inflammation marker
<i>Eosinophils</i>	%	2.5 ± 1.5	2.4 ± 1.8	Parasitic/Allergic response
<i>Ferritin</i>	ng/mL	100.0 ± 50.0	105.0 ± 60.0	Iron storage
<i>Transferrin</i>	mg/dL	250.0 ± 40.0	245.0 ± 50.0	Iron transport
<i>Iron</i>	mIU/L	100.0 ± 30.0	98.0 ± 35.0	Serum iron levels
<i>Urea</i>	mg/dL	30.0 ± 10.0	32.0 ± 12.0	Protein breakdown product
<i>Gamma-GT</i>	U/L	30.0 ± 15.0	35.0 ± 20.0	Liver enzyme



<i>CPK</i>	U/L	120.0 ± 40.0	115.0 ± 45.0	Muscle enzyme
<i>CO2</i>	mEq/L	26.0 ± 2.0	25.5 ± 2.5	Acis-base balance



4^ο στάδιο

Στο 4^ο στάδιο της ανάλυσης, ενισχύεται ο θόρυβος με την εισαγωγή επιπλέον 20 βιοδεικτών. Έτσι, το 4^ο στάδιο της ανάλυσης αφορά στην περίπτωση όπου ελέγχεται η ικανότητα ταξινόμησης δειγμάτων από τον kNN, με βάσει 10 βιοδείκτες που είναι γνωστό ότι σχετίζονται με την ανάπτυξη PDAC και συνολικά 50 βιοδείκτες οι οποίοι δεν έχουν καμία γνωστή -έως τώρα- συσχέτιση με την ανάπτυξη αυτού.

Αυστηρώς μαθηματικά, η συσχέτιση αυτή σημαίνει ότι το εύρος τιμών των 50 βιοδεικτών αυτών στην περίπτωση ενός ασθενούς με PDAC, δεν διαφέρει σημαντικά από το εύρος τιμών ενός υγιούς δείγματος.

Στην παρούσα ανάλυση, τον επιπλέον θόρυβο προσομοιώνουν οι 20 βιοδείκτες που φαίνονται στον παρακάτω πίνακα. Σημειώνεται ότι στις στήλες «Υγιής» και «Ασθενής», οι τιμές αφορούν την μέση τιμή του αντίστοιχου βιοδείκτη καθώς και την τυπική του απόκλιση.

Βιοδείκτης	Μονάδες	Υγιής	Ασθενής	Σημασία
<i>Vitamin B6</i>	ng/mL	15.0 ± 5.0	14.5 ± 6.0	Cofactor for enzymes; metabolic noise
<i>HCV Antibody</i>	Index	0.1 ± 0.02	0.1 ± 0.02	Hepatitis C screening; viral noise
<i>HBsAG</i>	Index	0.05 ± 0.01	0.05 ± 0.01	Hepatitis B screening; viral noise
<i>Rheumatoid Factor</i>	IU/mL	8.0 ± 3.0	8.5 ± 3.5	Autoimmune marker
<i>ANA Titer</i>	Ratio	1.0 ± 0.2	1.1 ± 0.3	Antinuclear marker
<i>Total Ige</i>	kU/L	50.0 ± 20.0	52.0 ± 25.0	Allergy related antibody
<i>Complement C3</i>	mg/dL	120.0 ± 15.0	118.0 ± 18.0	General immune system protein
<i>Complement C4</i>	mg/dL	25.0 ± 5.0	24.0 ± 6.0	General immune system protein
<i>ASO Titer</i>	IU/mL	100.0 ± 30.0	102.0 ± 35.0	Streptococcal infection history
<i>Prealbumin</i>	mg/dL	28.0 ± 5.0	27.0 ± 6.0	Short-term nutritional marker
<i>Zinc</i>	μg/dL	95.0 ± 15.0	93.0 ± 18.0	Essential trace element
<i>Copper</i>	μg/dL	110.0 ± 20.0	112.0 ± 25.0	Trace mineral for enzymes
<i>Selenium</i>	ng/mL	120.0 ± 15.0	118.0 ± 18.0	Parasitic/Allergic response
<i>Cortisol (morning)</i>	μg/dL	12.0 ± 4.0	13.0 ± 5.0	Antioxidant trace element



<i>FSH</i>	mIU/mL	6.0 ± 2.0	6.5 ± 2.5	Morning stress hormone baseline
<i>LH</i>	mIU/mL	5.0 ± 1.5	5.2 ± 2.0	Reproductive hormone baseline
<i>Vitamin A</i>	μg/dL	50.0 ± 12.0	48.0 ± 14.0	Fat-soluble vitamin
<i>Vitamin E</i>	mg/dL	12.0 ± 3.0	11.5 ± 3.5	Antioxidant vitamin
<i>Homocysteine</i>	μmol/L	9.0 ± 2.0	9.5 ± 2.5	Cardiovascular/metabolic risk
<i>Lactate</i>	mmol/L	1.2 ± 0.4	1.3 ± 0.5	Cellular metabolism marker



ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ

Η γενική διαδικασία που ακολουθήθηκε κατά την έρευνα, σε κάθε περίπτωση παρουσιάζεται συνοπτικά παρακάτω:

1. Στο πλαίσιο της προεπεξεργασίας (preprocessing) των δεδομένων, πραγματοποιήθηκε διαχείριση ακραίων τιμών (outliers handling), καθώς αυτές επηρεάζουν αρνητικά τους αλγορίθμους μηχανικής μάθησης κατά την διαδικασία της εκπαίδευσης τους. Συγκεκριμένα, εφαρμόστηκε μετασχηματισμός (transformation) των ακραίων αυτών τιμών ώστε να ενσωματωθούν στα υπόλοιπα δεδομένα.
2. Διαχωρισμός των δεδομένων σε δεδομένα εκπαίδευσης -training data- και δεδομένα αξιολόγησης -evaluation data-. Ο διαχωρισμός αυτός έγινε με βάση τα όρια που χρησιμοποιούνται κατά κόρον στην διεθνή βιβλιογραφία. Συγκεκριμένα, ως training data ορίστηκε το 75% του αρχικού dataset και ως evaluation data ορίστηκε το 25% του αρχικού dataset.
3. Εφαρμογή κανονικοποίησης (scaling) των δεδομένων, καθώς ο αλγόριθμος kNN βασιζόμενος στον υπολογισμό αποστάσεων, είναι εγγενώς ευαίσθητος ως προς το εύρος τιμών των χαρακτηριστικών του dataset. Πρακτικά, με την κανονικοποίηση περιορίζονται φαινόμενα bias λόγω μεγάλου εύρους τιμών των δεδομένων.
4. Παραμετροποίηση του μοντέλου.
5. Εφαρμογή Monte Carlo Cross Validation για την αξιολόγηση όλων των παραπάνω, μέσω των παραπάνω ειδικών μετρικών αξιολόγησης. Συγκεκριμένα, στην παρούσα έρευνα, τα μοντέλα εκτελούνται από 50 φορές έκαστο, για τον περιορισμό της τυχαιότητας στο πείραμα.
6. Εξαγωγή μέσης τιμής της κάθε μετρικής αξιολόγησης.

Παρακάτω ακολουθεί η παρουσίαση όλων των πειραματικών αποτελεσμάτων καθώς και ο σχολιασμός αυτών.

Η συγκεκριμένη παρουσίαση, συνοπτικά, περιλαμβάνει συγκριτικά διαγράμματα με σκοπό μια -κατά το δυνατόν- λεπτομερή σύγκριση και εξαγωγή τεκμηριωμένων συμπερασμάτων.




Τονίζεται ότι όπου γίνεται λόγος για «μέση τιμή», αυτή αφορά στη μέση τιμή της εν λόγω μετρικής που προκύπτει από το averaging των 50 εκτελέσεων κατά την εφαρμογή Monte Carlo Cross Validation.



Χρόνος εκτέλεσης των μοντέλων

Παρακάτω παρουσιάζονται συγκριτικά οι χρόνοι εκτέλεσης όλων των μοντέλων μηχανικής μάθησης που χρησιμοποιήθηκαν στην παρούσα έρευνα, σε όλα τα στάδια ανάλυσης.

Η συνεισφορά των παρακάτω διαγραμμάτων αφορά στο αν απαιτείται ικανοποιητικά χαμηλός χρόνος εκτέλεσης τους και στην τελική εξαγωγή συμπεράσματος αναφορικά με το αν αυτές αξίζουν να εφαρμοστούν ή όχι.





Από τα παραπάνω διαγράμματα προκύπτει το συμπέρασμα ότι όσο οι κλάσεις είναι εύκολα διαχωρίσιμες (version 1), ο χρόνος εκτέλεσης του αλγορίθμου kNN είναι σημαντικά μικρότερος σε σχέση με τις περιπτώσεις όπου οι κλάσεις είναι δύσκολα διαχωρίσιμες (version 2, 3 και 4).

Αυτή η ευκολία διαχωρισμού αφορά στην κατανομή των δεδομένων. Συγκεκριμένα, στις version 2, 3 και 4 κάθε μη σχετιζόμενος βιοδείκτης (χαρακτηριστικό) λαμβάνει πολύ μικρό εύρος τιμών ανεξάρτητα από το εάν αφορά σε υγιές ή ασθενές δείγμα. Αντίθετα, στην version 1 δεν ισχύει κάτι τέτοιο, πράγμα που δίνει την δυνατότητα ευκολότερου διαχωρισμού/ταξινόμησης των δειγμάτων σε κλάσεις.

Η αύξηση του χρόνου εκτέλεσης, φαίνεται να σχετίζεται απλώς και μόνο με την παρουσία μη σχετιζόμενων χαρακτηριστικών και όχι τόσο με το πλήθος αυτών, καθώς η δραματική αύξηση συμβαίνει στην περίπτωση εμφάνισης των πρώτων μη σχετιζόμενων χαρακτηριστικών (version 1 -> version 2), ενώ από εκεί και έπειτα η αύξηση του χρόνου εκτέλεσης με την προσθήκη επιπλέον μη σχετιζόμενων χαρακτηριστικών φαίνεται να μην υπάρχει.

Έτσι παρουσιάζεται συνοπτικά ο παρακάτω πίνακας ο οποίος περιέχει τις μέσες τιμές του χρόνου εκτέλεσης σε κάθε version, καθώς και του ρυθμός αύξησης (Growth Rate) της μετρικής αυτής από version σε version.

Version	Mean Execution Time	Growth Rate
Version 1	1.24	-
Version 2	22.10	1682.25%
Version 3	21.35	- 3.39%
Version 4	21.41	0.28%

Από τον παραπάνω καθίσταται σαφές ότι ο ρυθμός αύξησης του χρόνου εκτέλεσης από version 1 -> version 2 είναι δραματικός, ενώ στις άλλες περιπτώσεις δεν επηρεάζεται πρακτικά καθόλου (οι τόσο μικρές αυξομειώσεις που παρατηρούνται ενδέχεται να οφείλονται στις διακυμάνσεις της κατανομής των πόρων του λειτουργικού συστήματος).

Συνολικά, εγείρονται σημαντικά ερωτήματα αναφορικά με την εφαρμογή του αλγορίθμου σε real – life προβλήματα όντα παρατηρούνται τόσο μεγάλες διαφορές στον χρόνο εκτέλεσης.



Μετρικές αξιολόγησης της απόδοσης

Παρακάτω παρουσιάζονται εξατομικευμένα και συγκριτικά οι μετρικές που σχετίζονται με την απόδοση των μοντέλων. Οι μετρικές αυτές παρουσιάζονται για όλα τα μοντέλα μηχανικής μάθησης που χρησιμοποιήθηκαν στην παρούσα έρευνα. Συγκεκριμένα, παρουσιάζονται, για κάθε περίπτωση, οι μετρικές:









- Accuracy
- Precision
- Recall
- F1 – Score
- AUC – ROC



Σε κάθε περίπτωση, γίνεται εξατομικευμένη και -κατά το δυνατόν- εξονυχιστική μελέτη της κάθε μετρικής για την εξαγωγή ασφαλέστερου συμπεράσματος.



Τονίζεται ότι η απόδοση του αλγορίθμου kNN, είναι ευθέως ανάλογη της τιμής των παραπάνω μετρικών. Φυσικά, η ιδιαίτερη ερμηνεία της κάθε μετρικής συμβάλλει στην βέλτιστη αξιολόγηση του μοντέλου -σε κάθε περίπτωση- καθώς και στην εξαγωγή ορθών συμπερασμάτων.







Accuracy













Η μετρική accuracy αποτελεί μια από τις βασικές (αν όχι την βασικότερη) μετρική αξιολόγησης της απόδοσης αλγορίθμων μηχανικής μάθησης σε προβλήματα ταξινόμησης.

Η αξία της συγκεκριμένης μετρικής, έγκειται στο γεγονός ότι παρέχει μια μακροσκοπική ερμηνεία της ικανότητας του αλγορίθμου όσον αφορά την ορθή ταξινόμηση δειγμάτων σε κλάσεις. Όπως τονίστηκε και πρωτύτερα, η τιμή της accuracy είναι ευθέως ανάλογη με την απόδοση του αλγορίθμου.

Από τα παραπάνω διαγράμματα -αναφορικά με την μετρική accuracy- προκύπτουν διάφορα, ενδιαφέροντα και χρήσιμα συμπεράσματα.

Αρχικά, καθίσταται σαφής η μη παρουσία overfitting και underfitting καθώς οι τιμές της training accuracy και της evaluation accuracy είναι παρόμοιες. Αυτό παρατηρείται σε κάθε version του αλγορίθμου καθώς και σε κάθε περίπτωση, ανεξαρτήτως του αριθμού των γειτόνων (τιμής του «k») που χρησιμοποιείται. Επομένως, ο αλγόριθμος κάνει fit στα δεδομένα ικανοποιητικά καλά.

Στη συνέχεια, πραγματοποιείται ο έλεγχος ευρωστίας του αλγορίθμου. Γνωρίζοντας ότι ο συγκεκριμένος αλγόριθμος δεν είναι γενικά εύρωστος ένα πολύ χρήσιμο συμπέρασμα που βγαίνει από την μελέτη των διαγραμμάτων είναι, η αναμενόμενη, πτώση της accuracy όσο αυξάνεται ο θόρυβος. Συγκεκριμένα, ο αλγόριθμος φαίνεται συνεχώς να φθίνει όσο αυξάνεται ο αριθμός των χαρακτηριστικών που προστίθενται. Η πτώση αυτή, δεν φαίνεται να εξαρτάται από τον αριθμό των γειτόνων που χρησιμοποιούνται σε κάθε περίπτωση, πράγμα που σημαίνει ότι οποιαδήποτε προσπάθεια βελτίωσης του αλγορίθμου μέσω tuning της παραμέτρου αυτής, αναμένεται να μην αποδώσει.

Η παραπάνω παρατήρηση, όπως αναφέρθηκε, ήταν αναμενόμενη καθώς ένα από τα αρνητικά του αλγορίθμου αυτού είναι ότι επηρεάζεται (συνήθως σημαντικά) η απόδοσή του από την παρουσία θορύβου. Σκοπός της παρούσης έρευνας λοιπόν, αφορά στην μελέτη του ρυθμού πτώσης της απόδοσης του αλγορίθμου σε σχέση με την παρουσία του θορύβου και όχι στην παρατήρηση της πτώσης αυτής καθ' αυτής καθώς και στον πιθανό ορισμό ενός κατωφλίου (threshold accuracy) χρήσης του αλγορίθμου.

Τέλος, μια σημαντική παρατήρηση η οποία προκύπτει είναι ότι σε κάθε version, η accuracy φαίνεται να μην επηρεάζεται πρακτικά καθόλου (απειροελάχιστη μεταβολή – στα όρια του στατιστικού/υπολογιστικού λάθους) από τον αριθμό των γειτόνων που επιλέγεται. Αυτό, δίνει την δυνατότητα υπολογισμού μιας μέσης τιμής της accuracy σε κάθε version, ανεξαρτήτως της τιμής του «k», και έπειτα σύγκρισης αυτών για την εξαγωγή σχετικών συμπερασμάτων. Έτσι, παρουσιάζεται συνοπτικά ο παρακάτω πίνακας ο οποίος περιέχει τις μέσες τιμές της evaluation



accuracy σε κάθε version, καθώς και του ρυθμού πτώσης (degradation ratio) της μετρικής από version σε version.

Version	Mean Evaluation Accuracy	Degradation Ratio
Version 1	0.991	-
Version 2	0.953	3.83%
Version 3	0.857	10.07%
Version 4	0.723	15.64%



Από τον παραπάνω πίνακα καθίσταται σαφές ότι ο ρυθμός πτώσης της accuracy αυξάνεται καθώς αυξάνεται ο αριθμός των χαρακτηριστικών στο dataset, γεγονός που επιβεβαιώνει την θεωρητική γνώση περί μη ευρωστίας του αλγορίθμου.



Λόγω της βιοϊατρικής φύσης της έρευνας, φαίνεται το κατώφλι να ορίζεται αυστηρά στην version 1. Παρ, όλη την -ενδεχομένως να θεωρηθεί- μικρή πτώση που παρατηρείται από version 1 σε version 2, δηλαδή με την προσθήκη μόλις 10 μη σχετιζόμενων χαρακτηριστικών, επειδή οι βιοϊατρικές εφαρμογές πολλές φορές αποτελούν κρίσιμα ζητήματα ζωής και θανάτου, η πτώση αυτή κρίνεται ικανοποιητικά μεγάλη και απαγορευτική. Έτσι, σε περίπτωση ενός real-life σχετικού προβλήματος όπου ο αριθμός των χαρακτηριστικών είναι σχετικά μεγάλος, προτείνεται η χρήση τεχνικών feature selection, πριν την εφαρμογή του αλγορίθμου kNN.



Συνολικά, η accuracy δεν προσφέρει λεπτομερή εικόνα όσον αφορά την ικανότητα ταξινόμησης του αλγορίθμου και γι' αυτό προτείνεται η μελέτη της παράλληλα με την μελέτη και άλλων μετρικών.







Precision













Η μετρική precision αποτελεί και αυτή μια από τις βασικές μετρικές αξιολόγησης της απόδοσης αλγορίθμων μηχανικής μάθησης σε προβλήματα ταξινόμησης.

Η εν λόγω μετρική πρακτικά δίνει την απάντηση στην ερώτηση «Από όλα τα δείγματα που έχουν προβλεφθεί/ταξινομηθεί να έχουν καρκίνο, πόσα πραγματικά έχουν καρκίνο;». Κατευθείαν, γίνεται αντιληπτή η αξία αυτής της μετρικής καθώς περιγράφει πιο λεπτομερώς -σε σύγκριση με την accuracy- την απόδοση του αλγορίθμου. Φυσικά, και πάλι, η τιμή της precision είναι ευθέως ανάλογη με την απόδοση του αλγορίθμου.

Καθώς η παρούσα έρευνα αφορά βιοϊατρικά ζητήματα είναι απαραίτητη μια ερμηνεία της παρούσης μετρικής σε αυτό το πλαίσιο. Έτσι, καθίσταται σαφές ότι, η precision αποτελεί μια σημαντική μετρική αλλά όχι την σημαντικότερη και αυτό γίνεται κατανοητό από την μελέτη περιπτώσεων όπου η απόδοσή της χαρακτηρίζεται ως «χαμηλή». Σε αυτές τις περιπτώσεις, το αποτέλεσμα δεν χαρακτηρίζεται ως «κρίσιμα λανθασμένο» καθώς -πρακτικά- ένας υγιής ταξινομείται ως ασθενής (false positive). Αυτό, πρακτικά, σημαίνει ότι δεν κινδυνεύει άμεσα η ζωή του, γεγονός το οποίο είναι αφενός θετικό. Αφετέρου ωστόσο, ένα τέτοιο αποτέλεσμα δύναται να χαρακτηριστεί ως «έμμεση απειλή» καθώς ο εν λόγω άνθρωπος, πλην του γεγονότος ότι τρομάζει, στενοχωριέται και αγχώνεται για την ζωή του, ενδέχεται να προχωρήσει και σε ιατρικές πράξεις/θεραπείες οι οποίες θα τον εξαντλήσουν τόσο σωματικά όσο και ψυχικά.

Από τα παραπάνω διαγράμματα -αναφορικά με την μετρική precision- προκύπτει ένα και μόνο κρίσιμο συμπέρασμα. Η απόδοση του αλγορίθμου kNN, μόνο όσον αφορά την precision, δεν φαίνεται να επηρεάζεται καθόλου, ούτε από τον αριθμό των γειτόνων που χρησιμοποιούνται ούτε από τον αριθμό των δειγμάτων (είτε σχετιζόμενων είτε μη σχετιζόμενων). Η Precision, σε κάθε περίπτωση είναι «καρφωμένη» στο 100%, επομένως δεν παρατηρούνται φαινόμενα false positive περιπτώσεων. Έτσι, ο αλγόριθμος χαρακτηρίζεται ως «απόλυτα εύρωστος» σε αυτήν την περίπτωση.

Για λόγους πληρότητας και ομοιομορφίας της έρευνας, παρουσιάζεται συνοπτικά ο παρακάτω πίνακας ο οποίος περιέχει τις μέσες τιμές της evaluation precision σε κάθε version, καθώς και του ρυθμού πτώσης (degradation ratio) της μετρικής από version σε version.



Version	Mean Precision Accuracy	Degradation Ratio
Version 1	1.000	-
Version 2	1.000	0.00%
Version 3	1.000	0.00%
Version 4	1.000	0.00%







Συνολικά, η precision προσφέρει μια λεπτομερή εικόνα όσον αφορά την ικανότητα ταξινόμησης του αλγορίθμου και γι' αυτό προτείνεται η μελέτη της. Φυσικά, για μια πιο ολοκληρωμένη εικόνα, προτείνεται να μελετάται παράλληλα και με άλλες μετρικές.







Recall













Η μετρική recall αποτελεί και αυτή μια από τις βασικές μετρικές αξιολόγησης της απόδοσης αλγορίθμων μηχανικής μάθησης σε προβλήματα ταξινόμησης. Τις περισσότερες φορές, σε εφαρμογές βιοϊατρικής φύσεως, η recall αποτελεί την σημαντικότερη μετρική αξιολόγησης ενός μοντέλου.

Η εν λόγω μετρική πρακτικά δίνει την απάντηση στην ερώτηση «Από όλα τα δείγματα που πραγματικά έχουν καρκίνο, πόσα προβλέφθηκαν/ταξινομήθηκαν να έχουν καρκίνο;». Κατευθείαν, γίνεται αντιληπτή η αξία αυτής της μετρικής καθώς αφενός περιγράφει πιο λεπτομερώς -σε σύγκριση με την accuracy- την απόδοση του αλγορίθμου και αφετέρου απαντάει σε ένα πιο κρίσιμο ερώτημα από την precision. Φυσικά, και πάλι, η τιμή της recall είναι ευθέως ανάλογη με την απόδοση του αλγορίθμου.

Καθώς η παρούσα έρευνα αφορά βιοϊατρικά ζητήματα είναι απαραίτητη μια ερμηνεία της παρούσης μετρικής σε αυτό το πλαίσιο. Έτσι, καθίσταται σαφές ότι, η recall αποτελεί την σημαντικότερη μετρική και αυτό γίνεται κατανοητό από την μελέτη περιπτώσεων όπου η απόδοσή της χαρακτηρίζεται ως «χαμηλή». Σε αυτές τις περιπτώσεις, το αποτέλεσμα χαρακτηρίζεται ως «κρίσιμα λανθασμένο» καθώς -πρακτικά- ένας ασθενής ταξινομείται ως υγιής (false negative). Αυτό, πρακτικά, σημαίνει ότι κινδυνεύει άμεσα η ζωή του, γεγονός το οποίο είναι πολύ αρνητικό. Μια τέτοια ταξινόμηση πρακτικά, απειλεί άμεσα την ζωή του (πραγματικά) ασθενούς, καθυστερεί την ενδεχόμενη θεραπεία στην οποία πρέπει να υποβληθεί μειώνοντας τις πιθανότητες επιβίωσής του σημαντικότερα. Γι' αυτό τον λόγο, σε εφαρμογές βιοϊατρικής η recall επιδιώκεται όχι απλώς να έχει υψηλή τιμή, αλλά πολύ υψηλή.

Αναφορικά με τον έλεγχο ευρωστίας με βάση την recall, γνωρίζοντας ότι ο συγκεκριμένος αλγόριθμος δεν είναι γενικά εύρωστος ένα πολύ χρήσιμο συμπέρασμα που βγαίνει από την μελέτη των διαγραμμάτων είναι, η αναμενόμενη, πτώση της recall όσο αυξάνεται ο θόρυβος. Συγκεκριμένα, ο αλγόριθμος φαίνεται συνεχώς να φθίνει σημαντικά όσο αυξάνεται ο αριθμός των χαρακτηριστικών που προστίθενται. Η πτώση αυτή, ειδικά στις version 3 και version 4, δηλαδή στις περιπτώσεις με πολλά μη σχετιζόμενα χαρακτηριστικά, φαίνεται να εξαρτάται και από τον αριθμό των γειτόνων που χρησιμοποιούνται σε κάθε περίπτωση. Συγκεκριμένα, η αύξηση του αριθμού των γειτόνων, φαίνεται να επηρεάζει αρνητικά την recall, δηλαδή οδηγεί σε πτώση της τιμής της.

Η παραπάνω παρατήρηση, όπως αναφέρθηκε, ήταν αναμενόμενη καθώς ένα από τα αρνητικά του αλγορίθμου αυτού είναι ότι επηρεάζεται (συνήθως σημαντικά) η απόδοσή του από την παρουσία θορύβου. Σκοπός της παρούσης έρευνας λοιπόν, αφορά στην μελέτη του ρυθμού πτώσης της απόδοσης του αλγορίθμου σε σχέση με την παρουσία του θορύβου και όχι στην παρατήρηση της πτώσης αυτής καθ' αυτής καθώς και στον πιθανό ορισμό ενός κατωφλίου (threshold recall) χρήσης του αλγορίθμου.



Τέλος, στην προσπάθεια ορισμού ενός κατωφλίου χρήσης της recall, αρχικά υπολογίζεται η μέση τιμή της recall σε κάθε version, ανεξαρτήτως της τιμής του «k», και έπειτα συγκρίνονται αυτές για την εξαγωγή σχετικών συμπερασμάτων. Έτσι, παρουσιάζεται συνοπτικά ο παρακάτω πίνακας ο οποίος περιέχει τις μέσες τιμές της evaluation recall σε κάθε version, καθώς και του ρυθμού πτώσης (degradation ratio) της μετρικής από version σε version.

Version	Mean Recall Accuracy	Degradation Ratio
Version 1	0.982	-
Version 2	0.906	7.74%
Version 3	0.714	21.19%
Version 4	0.447	37.39%





Από τον παραπάνω πίνακα καθίσταται σαφές ότι ο ρυθμός πτώσης της recall αυξάνεται δραματικά με την αύξηση του αριθμού των χαρακτηριστικών στο dataset, γεγονός που επιβεβαιώνει την θεωρητική γνώση περί μη ευρωστίας του αλγορίθμου.



Λόγω της βιοϊατρικής φύσης της έρευνας, φαίνεται το κατώφλι να ορίζεται αυστηρά στην version 1. Παρ, όλη την -ενδεχομένως να θεωρηθεί- μικρή πτώση που παρατηρείται από version 1 σε version 2, δηλαδή με την προσθήκη μόλις 10 μη σχετιζόμενων χαρακτηριστικών, επειδή οι βιοϊατρικές εφαρμογές πολλές φορές αποτελούν κρίσιμα ζητήματα ζωής και θανάτου, η πτώση αυτή κρίνεται ικανοποιητικά μεγάλη και απαγορευτική. Έτσι, σε περίπτωση ενός real-life σχετικού προβλήματος όπου ο αριθμός των χαρακτηριστικών είναι σχετικά μεγάλος, προτείνεται η χρήση τεχνικών feature selection, πριν την εφαρμογή του αλγορίθμου kNN.



Συνολικά, η recall προσφέρει μια λεπτομερή εικόνα όσον αφορά την ικανότητα ταξινόμησης του αλγορίθμου και γι' αυτό προτείνεται η μελέτη της. Φυσικά, για μια πιο ολοκληρωμένη εικόνα, προτείνεται να μελετάται παράλληλα και με άλλες μετρικές.







F1 – Score













Η μετρική F1 – Score αποτελεί και αυτή μια από τις βασικές μετρικές αξιολόγησης της απόδοσης αλγορίθμων μηχανικής μάθησης σε προβλήματα ταξινόμησης. Λόγω της φύσης της, δηλαδή λόγω του γεγονότος ότι αντιμετωπίζει την precision και την recall με το ίδιο βάρος, σε εφαρμογές βιοϊατρικής φύσεως, η F1 – Score δεν αποτελεί σημαντική αποτελεί την σημαντικότερη μετρική αξιολόγησης ενός μοντέλου. Αυτό συμβαίνει καθώς η μετρική recall πρέπει να έχει περισσότερη βαρύτητα από την μετρική precision σε αυτές τις εφαρμογές.

Η εν λόγω μετρική, πρακτικά, δίνει την απάντηση στην ερώτηση «Ποιος είναι ο αρμονικός μέσος όρος της precision και της recall;». Ιδανικά, η μελέτη της έχει μεγάλη αξία σε περιπτώσεις όπου η precision και η recall πρέπει να έχουν το ίδιο βάρος.

Στην συγκεκριμένη έρευνα, καθώς η precision είναι «καρφωμένη» στο 1 σε όλες τις περιπτώσεις, λογικά η F1 – Score θα ακολουθεί, αναλογικά, τις διακυμάνσεις της recall. Επομένως, αναφορικά με τον έλεγχο ευρωστίας, ισχύει ό,τι ισχύει και για την recall.

Για λόγους πληρότητας και ομοιομορφίας της έρευνας, παρουσιάζεται συνοπτικά ο παρακάτω πίνακας ο οποίος περιέχει τις μέσες τιμές της evaluation F1 – Score σε κάθε version, καθώς και του ρυθμού πτώσης (degradation ratio) της μετρικής από version σε version.

Version	Mean F1 – Score Accuracy	Degradation Ratio
Version 1	0.991	-
Version 2	0.950	4.13%
Version 3	0.831	12.53%
Version 4	0.621	25.27%

Από τον παραπάνω πίνακα καθίσταται σαφές ότι ο ρυθμός πτώσης της F1 – Score αυξάνεται πολύ με την αύξηση του αριθμού των χαρακτηριστικών στο dataset, γεγονός που επιβεβαιώνει την θεωρητική γνώση περί μη ευρωστίας του αλγορίθμου.





Λόγω της βιοϊατρικής φύσης της έρευνας, φαίνεται το κατώφλι να ορίζεται αυστηρά στην version 1. Παρ, όλη την -ενδεχομένως να θεωρηθεί- μικρή πτώση που παρατηρείται από version 1 σε version 2, δηλαδή με την προσθήκη μόλις 10 μη σχετιζόμενων χαρακτηριστικών, επειδή οι βιοϊατρικές εφαρμογές πολλές φορές αποτελούν κρίσιμα ζητήματα ζωής και θανάτου, η πτώση αυτή κρίνεται ικανοποιητικά μεγάλη και απαγορευτική. Επίσης, γνωρίζοντας ότι η πτώση αυτή οφείλεται σε πτώση της recall (σ.σ. σημαντικότερης μετρικής), καθίσταται σαφές ότι η πτώση οφείλεται σε πραγματικά σημαντικό παράγοντα. Έτσι, σε περίπτωση ενός real-life σχετικού προβλήματος όπου ο αριθμός των χαρακτηριστικών είναι σχετικά μεγάλος, προτείνεται η χρήση τεχνικών feature selection, πριν την εφαρμογή του αλγορίθμου kNN.







Συνολικά, η F1 – Score προσφέρει μια μακροσκοπική, μέση εικόνα όσον αφορά την ικανότητα ταξινόμησης του αλγορίθμου και γι' αυτό προτείνεται συχνά η μελέτη της. Φυσικά, για μια πιο ολοκληρωμένη εικόνα, προτείνεται να μελετάται παράλληλα και με άλλες μετρικές.







AUC – ROC













Η μετρική AUC – ROC αποτελεί και αυτή μια από τις βασικές μετρικές αξιολόγησης της απόδοσης αλγορίθμων μηχανικής μάθησης σε προβλήματα ταξινόμησης.

Η εν λόγω μετρική, πρακτικά, δίνει την απάντηση στην ερώτηση «Πόσο καλά το μοντέλο ξεχωρίζει δείγματα ασθενών από δείγματα υγιών με βάση κάθε πιθανό κατώφλι απόφασης (decision threshold);». Συγκεκριμένα, λαμβάνει μια τιμή από 0.5 έως 1, όπου 0.5 σημαίνει καμία διαχωριστική ικανότητα και 1 σημαίνει απόλυτα ορθή διαχωριστική ικανότητα. Μια άλλη ερμηνεία που συνήθως δίνεται στην AUC – ROC είναι η εξής: «Αν επιλεγεί τυχαία έναν ασθενή και έναν υγιή, η AUC – ROC αντιστοιχεί στην πιθανότητα το μοντέλο να αναθέσει υψηλότερο σκορ ρίσκου (risk score) στον ασθενή».

Η AUC – ROC, λόγω της τεχνικής της φύσης, δύναται να είναι λιγότερο σημαντική από άλλες μετρικές αξιολόγησης σε βιοϊατρικά ζητήματα όπου η παρουσία false negatives (πρακτικά ταξινομείται έναν ασθενή ως υγιή) χαρακτηρίζεται κρίσιμη. Αυτό, συμβαίνει και στην παρούσα έρευνα, επομένως καθίσταται σαφές ότι η AUC – ROC, αφενός είναι σημαντική για την μακροσκοπική εικόνα του μοντέλου ωστόσο μετρικές, όπως η recall, είναι σημαντικότερες.

Αναφορικά με τον έλεγχο ευρωστίας με βάση την AUC – ROC, γνωρίζοντας (θεωρητικά) ότι ο συγκεκριμένος αλγόριθμος δεν είναι γενικά εύρωστος ένα πολύ χρήσιμο συμπέρασμα που βγαίνει από την μελέτη των διαγραμμάτων είναι αφενός η φαινομενική πτώση της AUC – ROC όσο αυξάνεται ο θόρυβος, αφετέρου δε αυτή η πτώση αυτή χαρακτηρίζεται ως αρκετά χαμηλή και συμβαίνει υπό συγκεκριμένες προϋποθέσεις. Συγκεκριμένα, η πτώση συμβαίνει μόνο σε περιπτώσεις όπου αυξάνονται τα μη σχετιζόμενα χαρακτηριστικά αλλά φαίνεται να περιορίζεται (και μάλιστα αρκετά ικανοποιητικά) με τη αύξηση του αριθμού των γειτόνων που χρησιμοποιούνται. Έτσι, με βάση την μετρική αυτή, παρέχεται η δυνατότητα fine tuning τέτοιων μοντέλων.

Όπως και στις προηγούμενες μετρικές, ελέγχεται η δυνατότητα πιθανού ορισμού ενός κατωφλίου (threshold AUC – ROC) χρήσης του αλγορίθμου.

Παρακάτω, παρουσιάζεται συνοπτικά ο παρακάτω πίνακας ο οποίος περιέχει τις μέσες τιμές της evaluation AUC – ROC σε κάθε version, καθώς και του ρυθμού πτώσης (degradation ratio) της μετρικής από version σε version.

Version	Mean AUC – ROC Accuracy	Degradation Ratio
Version 1	0.999	-
Version 2	0.984	1.5%
Version 3	0.981	0.3%
Version 4	0.951	3.04%



Από τον παραπάνω πίνακα καθίσταται σαφές ότι ο ρυθμός πτώσης της AUC – ROC είναι ανεξάρτητος του αριθμού των μη σχετιζόμενων χαρακτηριστικών στο dataset, γεγονός που χρήζει ερμηνείας, καθώς έρχεται σε αντίθεση με την θεωρητική γνώση περί μη ευρωστίας του αλγορίθμου. Η ερμηνεία που δίνεται είναι ότι η αντιστάθμιση της αναμενόμενης πτώσης οφείλεται στην αύξηση του αριθμού των γειτόνων, γεγονός που καθιστά το μοντέλο να συμπεριφέρεται αρκετά καλά (πάντα σε σύγκριση με την αναμενόμενη συμπεριφορά του).

Αναφορικά με τον ορισμό του κατωφλίου χρήσης, λόγω της βιοϊατρικής φύσης της έρευνας, φαίνεται ότι το κατώφλι δύναται να οριστεί τόσο στην version 1, στην version 2 αλλά και στην version 3. Παρ' όλη την (ελάχιστη) πτώση που παρατηρείται από version σε version, η τιμή της μετρικής στην version 3 είναι ικανοποιητικά υψηλή για μια εφαρμογή τέτοιας φύσεως. Ωστόσο, λόγω της τεχνικής της φύσης (δύναται να μην δίνει την επιθυμητή βαρύτητα σε false negative περιπτώσεις), δεν είναι η καταλληλότερη μετρική με βάση την οποία βγαίνει το τελικό συμπέρασμα. Φυσικά και αυτή συμβάλει, με την βαρύτητά της, στην εξαγωγή τελικού ολοκληρωμένου συμπεράσματος.

Συνολικά, η AUC – ROC προσφέρει μια μακροσκοπική εικόνα όσον αφορά την ικανότητα ταξινόμησης του αλγορίθμου και γι' αυτό προτείνεται συχνά η μελέτη της. Φυσικά, για μια πιο ολοκληρωμένη εικόνα, προτείνεται να μελετάται παράλληλα και με άλλες μετρικές.





Μετρικές του confusion matrix

Παρακάτω, για λόγους πληρότητας, επιβεβαίωσης των παραπάνω παρατηρήσεων, και ενίσχυσης των προαναφερθέντων συμπερασμάτων παρουσιάζονται συγκριτικά οι μετρικές που σχετίζονται με τον confusion matrix. Οι μετρικές αυτές παρουσιάζονται για όλα τα μοντέλα μηχανικής μάθησης που χρησιμοποιήθηκαν στην παρούσα έρευνα. Συγκεκριμένα, παρουσιάζονται, για κάθε περίπτωση, οι μέσες τιμές των μετρικών:

- True Positives (TP): Η απόδοση του μοντέλου είναι ανάλογη της τιμής της εν λόγω μετρικής.
- True Negatives (TN): Η απόδοση του μοντέλου είναι ανάλογη της τιμής της εν λόγω μετρικής.
- False Positives (FP): Η απόδοση του μοντέλου είναι αντιστρόφως ανάλογη της τιμής της εν λόγω μετρικής.
- False Negatives (FN): Η απόδοση του μοντέλου είναι αντιστρόφως ανάλογη της τιμής της εν λόγω μετρικής.





True Positives







True Negatives







False Positives





False Negatives





ΣΥΜΠΕΡΑΣΜΑΤΑ

Παρακάτω παρουσιάζονται συνοπτικά τα συμπεράσματα τα οποία προέκυψαν από την παρούσα έρευνα.

Ως αφορμή για την παρούσα έρευνα στάθηκε το ερώτημα «Μπορούν να χρησιμοποιηθούν -προς το παρόν- μη σχετιζόμενοι βιοδείκτες για την ταξινόμηση δειγμάτων σε υγιείς και ασθενείς για περιπτώσεις αδενοκαρκινώματος των παγκρεατικών πόρων;».

Το ερώτημα αυτό, πρακτικά, τεχνικά αφορά στον έλεγχο ευρωστίας του αλγορίθμου kNN, παρουσία μεταβαλλόμενων τιμών θορύβου, δηλαδή ελέγχου της απόδοσης του μέσω συνεχούς αύξησης μη σχετιζόμενων χαρακτηριστικών.

Ο έλεγχος ευρωστίας επιβεβαίωσε την θεωρητική υπόθεση κατά την οποία ο αλγόριθμος αυτός γενικά δεν είναι εύρωστος, αλλά επηρεάζεται (και πολλές φορές σημαντικά) από τον θόρυβο. Συγκεκριμένα, παρατηρήθηκε σε αρκετές μετρικές (π.χ. accuracy) πτώση της απόδοσης του αλγορίθμου. Το σημαντικότερο συμπέρασμα ωστόσο, το οποίο θέτει ως απαγορευτική την χρήση του συγκεκριμένου αλγορίθμου σε παρόμοιες εφαρμογές είναι η σημαντικά χαμηλή τιμή της μετρικής recall, η οποία όπως τονίστηκε πολλές φορές είναι η πλέον σημαντική μετρική σε παρόμοιες εφαρμογές.

Παράλληλα και λόγω του γεγονότος ότι η γενική πτώση της απόδοσης του αλγορίθμου είναι αναμενόμενη και προφανής, η έρευνα δεν περιορίστηκε μόνο σε αυτό αλλά πραγματοποιήθηκε και μια προσπάθεια αφενός παρατήρησης του ρυθμού πτώσης της απόδοσης του σε σχέση με την παρουσία μη σχετιζόμενων χαρακτηριστικών στο dataset και αφετέρου ο ορισμός ενός κατωφλίου χρήσης του αλγορίθμου. Τα συμπεράσματα που αφορούν την κάθε μετρική εξετασθέντα, δίνοντας το ειδικό βάρος που αναλογεί στην καθεμιά, παρουσιάζονται στην ενότητα «ΠΕΙΡΑΜΑΤΙΚΑ ΑΠΟΤΕΛΕΣΜΑΤΑ» σε σχετικό πίνακάκι και πλησίον αυτού.

Τέλος, αναφορικά με τον εντοπισμό επιπλέον -ενδεχομένως- σημαντικών βιοδεικτών σχετιζόμενων με την ανάπτυξη PDAC, δεν καθίσταται δυνατό από αυτήν την έρευνα.



ΠΡΟΤΕΙΝΟΜΕΝΗ ΜΕΛΛΟΝΤΙΚΗ ΕΡΕΥΝΑ

Παρακάτω παρουσιάζεται η προτεινόμενη μελλοντική έρευνα η οποία προτείνεται με βάση τα συμπεράσματα που προέκυψαν από τούτη την έρευνα.

Έτσι, προτείνεται:

- Feature selection για τον ενδεχόμενο εντοπισμό επιπλέον σημαντικών βιοδεικτών για την διάγνωση του συγκεκριμένου τύπου καρκίνου.
- Real – life data για βέλτιστη απόδοση της πραγματικότητας.
- Περισσότερα δείγματα για πιο ολοκληρωμένη αξιολόγηση του αλγορίθμου.
Εφαρμογή σε περισσότερου τύπους καρκίνου, καθώς σε περίπτωση που ένας σχετικά απλός αλγόριθμος χαρακτηριστεί ως ικανοποιητικός, δύναται να συμβάλει στην αντιμετώπιση του PDAC με χαμηλό οικονομικό κόστος (περιορίζεται η χρήση μεγάλων υπολογιστικών συστημάτων με κοστοβόρους αλγορίθμους για τον εντοπισμό PDAC).
- Εφαρμογή και άλλων αλγορίθμων για σύγκριση της απόδοσής τους